

۱ بخش ۱

۲ پیاده‌سازی دستی الگوریتم Isomap

در این بخش، الگوریتم Isomap را بدون استفاده از توابع آماده‌ی کتابخانه‌ها مانند scikit-learn پیاده‌سازی کرده‌ایم. هدف اصلی، درک بهتر مراحل الگوریتم و مقایسه نتایج آن با نسخه‌ی کتابخانه‌ای است.

۱-۲ ساخت گراف k -نزدیک‌ترین همسایه‌ها

ابتدا برای هر نقطه، k تا از نزدیک‌ترین نقاط دیگر را با استفاده از فاصله اقلیدسی پیدا می‌کنیم. برای این کار:

- یک ماتریس فاصله (Distance Matrix) بین تمامی نمونه‌ها محاسبه می‌کنیم.
- سپس برای هر سطر، k مقدار کوچک‌تر (غیر صفر) را نگه می‌داریم.
- مقادیر دیگر را برابر با بی‌نهایت (∞) قرار می‌دهیم تا مسیر مستقیم بین آن نقاط در گراف قطع شود.
- این کار منجر به ساخت گرافی می‌شود که تنها یال‌های مربوط به k همسایه‌ی نزدیک هر نقطه را شامل می‌شود.

۲-۲ محاسبه‌ی فاصله‌های ژئودزیک با الگوریتم Floyd-Warshall

برای تخمین فاصله‌ی ژئودزیک بین هر دو نقطه، از الگوریتم Floyd-Warshall استفاده کردیم که برای گراف‌های وزن‌دار جهت‌دار مناسب است. این الگوریتم برای تمامی جفت گره‌ها، کوتاه‌ترین مسیر را محاسبه می‌کند.

- ورودی: ماتریس وزن‌دار گراف (با ∞ برای یال‌های غیرفعال)
- خروجی: ماتریس فاصله‌ی ژئودزیک بین همه‌ی جفت نقاط

۳-۲ کاهش بُعد با استفاده از MDS

پس از محاسبه ماتریس فاصله‌ی ژئودزیک، از Multidimensional Scaling (MDS) برای نگاشت داده‌ها به فضای دوبعدی استفاده کردیم. مراحل انجام MDS به شرح زیر است:

۱. محاسبه‌ی ماتریس فاصله‌ی مربعی D^2 با استفاده از فواصل ژئودزیک.

۲. مرکزسازی داده‌ها با استفاده از ماتریس $H = I - \frac{1}{n}ee^T$ و محاسبه‌ی:

$$B = -\frac{1}{2}HD^2H$$

۳. انجام تجزیه‌ی مقادیر ویژه روی ماتریس B و استخراج بردارهای ویژه متناظر با دو مقدار ویژه بزرگ‌تر برای نگاشت دوبعدی.

۴-۲ چرخش و بازتاب نگاشت Isomap

برای هماهنگ‌سازی جهت‌گیری نگاشت Isomap با نقشه‌های جغرافیایی متداول، دو گام زیر انجام شده است: به زبان ریاضی:


$$(x_{\text{rot}}, y_{\text{rot}}) = (-y, x),$$

$$(x_{\text{final}}, y_{\text{final}}) = (-x_{\text{rot}}, y_{\text{rot}}) = (y, x).$$

این تبدیل باعث می‌شود که جهت‌های شرقی-غربی و شمالی-جنوبی در نگاشت نهایی با انتظار ما از نقشه‌های جغرافیایی هم‌راستا شوند (شرق به راست و شمال به بالا).

۵-۲ تفسیر نگاشت پس از چرخش

شکل زیر نگاشت دوبعدی شهرهای ایران را پس از چرخش و بازتاب نشان می‌دهد:




شکل ۱: نگاشت Isomap پس از چرخش و بازتاب

- شمال غرب: شهرهای Urmia و Tabriz در بالای نگاشت و اندکی به چپ قرار دارند.
 - شمال شرق: شهرهای Ardabil و Zanzan در بالا و راست متمرکز شده‌اند.
 - مرکز: Tehran، Qom و Arak نزدیک مرکز قرار گرفته‌اند که نشان‌دهنده کانون جغرافیایی ایران است.
 - جنوب غرب: شهرهای Bushehr، Shiraz و Yasuj در نیمه پایین و سمت چپ نگاشت واقع شده‌اند.
 - جنوب شرق: Zahedan و Birjand در پایین و راست نگاشت دیده می‌شوند.
- این چینش نشان‌دهنده حفظ ساختار ژئودزیک (فاصله‌های زمینی بر اساس کوتاه‌ترین مسیر در گراف همسایگی) توسط الگوریتم Isomap است و نزدیکی‌های جغرافیایی شهرها را به خوبی در فضای کم بعد منعکس می‌کند.

۶-۲ نتیجه ایزومپ کتابخانه sklearn

نتیجه‌ی حاصل از تحلیل پراکستس بین نگاشت دو بُعدی پیاده‌سازی شده‌ی دستی و نگاشت حاصل از کتابخانه‌ی sklearn برابر با صفر است ($\text{Procrustes disparity} = 0.000000$). این مقدار نشان‌دهنده‌ی هم‌پوشانی کامل و دقیق بین این دو نگاشت، پس از اعمال تبدیل‌های ایزومتريک (مانند دوران، انتقال و بازتاب) است. به عبارت دیگر، ساختار کلی داده‌ها در فضای کم‌بعدی در هر دو پیاده‌سازی به‌صورت یکسان حفظ شده است و تفاوتی از نظر هندسه‌ی نسبی نقاط وجود ندارد. این نتیجه دقت بالای پیاده‌سازی دستی الگوریتم ISOMAP را تأیید می‌کند.



شکل ۲: خروجی sklearn پس از اعمال نگاشت چرخش

۳ بخش ۲: سوالات تشریحی

۱-۳ سوال ۱

از تعریف کوواریانس داریم:

$$\Sigma = \frac{1}{m-1} X^T X.$$

با جایگذاری تجزیه مقدار تکین $X = USV^T$:

$$X^T X = (USV^T)^T (USV^T) = V S^T U^T U S V^T.$$

از آن جا که U متعامد است، $U^T U = I$ ، بنابراین:

$$X^T X = V S^T S V^T.$$

پس:

$$\Sigma = \frac{1}{m-1} V S^T S V^T.$$

اکنون توجه کنید که S یک ماتریس قطری-مستطیلی است. اگر رتبه X برابر r باشد، می توان نوشت:

$$S = \begin{bmatrix} \text{diag}(s_1, \dots, s_r) & 0 \\ 0 & 0 \end{bmatrix}, \quad s_1 \geq \dots \geq s_r > 0,$$

که در آن s_i ها مقادیر تکین X هستند. در این حالت،

$$S^T S = \begin{bmatrix} \text{diag}(s_1^2, \dots, s_r^2) & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

پس می توان Σ را به صورت یک تجزیه ویژه نوشت:

$$\Sigma = V \left(\frac{1}{m-1} S^T S \right) V^T.$$

از آن جا که V متعامد است و ماتریس $\frac{1}{m-1} S^T S$ قطری و با درایه های غیرمنفی است، نتیجه می شود:

- بردارهای ویژه Σ برابر ستون‌های V هستند (یعنی v_i ها).
- مقادیر ویژه Σ برابر مربع مقادیر تکین تقسیم بر $(m-1)$ هستند:

$$\lambda_i(\Sigma) = \frac{s_i^2}{m-1}, \quad i = 1, \dots, r,$$

و برای $i > r$ (در صورت $r < n$) داریم $\lambda_i(\Sigma) = 0$.

برای مشاهده مستقیم، اگر $V = [v_1, \dots, v_n]$ باشد، آنگاه:

$$\Sigma v_i = \frac{1}{m-1} V S^T S V^T v_i = \frac{1}{m-1} V S^T S e_i = \frac{s_i^2}{m-1} v_i,$$

که نشان می‌دهد v_i بردار ویژه و $\frac{s_i^2}{m-1}$ مقدار ویژه متناظر است.

۲-۳ سوال ۲

صورت‌بندی هندسی تصویر و خطا

فرض کنید $u \in \mathbb{R}^n$ یک بردار یکه باشد ($\|u\|_2 = 1$). تصویر عمودی x_i روی زیرفضای یک‌بُعدی $\text{span}(u)$ برابر است با:

$$F(x_i) = \hat{x}_i = (u^T x_i) u.$$

بردار خطای بازسازی (مولفه عمود بر زیرفضا) نیز:

$$e_i = x_i - \hat{x}_i = x_i - (u^T x_i) u.$$

(۱) هم‌ارزی بیشینه‌سازی طول تصویر و کمینه‌سازی خطا

چون $\hat{x}_i$ تصویر عمودی روی $\text{span}(u)$ است، داریم $\hat{x}_i \perp e_i$ و لذا از قضیه فیثاغورس:

$$\|x_i\|_2^2 = \|\hat{x}_i\|_2^2 + \|e_i\|_2^2.$$

از طرفی چون $\|u\|_2 = 1$:

$$\|\hat{x}_i\|_2^2 = \|(u^T x_i)u\|_2^2 = (u^T x_i)^2 \|u\|_2^2 = (u^T x_i)^2.$$

پس برای هر i :

$$\|e_i\|_2^2 = \|x_i\|_2^2 - (u^T x_i)^2.$$

اکنون مجموع خطای بازسازی (معیار رایج کمینه‌سازی در PCA) را در نظر بگیرید:

$$J(u) = \sum_{i=1}^m \|e_i\|_2^2 = \sum_{i=1}^m \|x_i\|_2^2 - \sum_{i=1}^m (u^T x_i)^2.$$

چون داده‌ها ثابت‌اند، عبارت $\sum_{i=1}^m \|x_i\|_2^2$ مستقل از u است؛ بنابراین:

$$\arg \min_{\|u\|_2=1} J(u) = \arg \max_{\|u\|_2=1} \sum_{i=1}^m (u^T x_i)^2.$$

اما $\sum_{i=1}^m (u^T x_i)^2$ دقیقاً مجموع مربع «طول تصویر اسکالر» روی u است. همچنین چون داده‌ها مرکزسازی شده‌اند، میانگین $u^T x_i$ صفر است و واریانس تصویرهای اسکالر $y_i = u^T x_i$ برابر است با:

$$\text{Var}(y) = \frac{1}{m-1} \sum_{i=1}^m (u^T x_i)^2.$$

پس بیشینه‌کردن $\sum_i (u^T x_i)^2$ معادل بیشینه‌کردن واریانس داده‌های تصویر شده است. نتیجه:

کمینه‌سازی خطای بازسازی (کمترین مربعات). $\iff$ بیشینه‌سازی واریانس تصویرها

بیان ماتریسی (رابطه با کوواریانس)

اگر $X \in \mathbb{R}^{m \times n}$ ماتریس داده‌های مرکزسازی شده باشد (سطرها نمونه‌ها)، آنگاه:

$$\sum_{i=1}^m (u^T x_i)^2 = \|Xu\|_2^2 = u^T X^T X u.$$

با تعریف کواریانس نمونه‌ای

$$\Sigma = \frac{1}{m-1} X^T X,$$

داریم:

$$\text{Var}(Xu) = \frac{1}{m-1} \|Xu\|_2^2 = u^T \Sigma u.$$

پس مسئله بیشینه‌سازی واریانس به شکل کلاسیک ریلی (Rayleigh quotient) درمی‌آید:

$$\max_{\|u\|_2=1} u^T \Sigma u,$$

که جواب آن بردار ویژه متناظر با بزرگ‌ترین مقدار ویژه Σ است.

(۲) نتیجه درباره اطلاعات از دست‌رفته در کاهش بعد

از رابطه فیثاغورس برای هر نمونه:

$$\|x_i\|_2^2 = \|\hat{x}_i\|_2^2 + \|e_i\|_2^2,$$

و با جمع روی همه نمونه‌ها:

$$\sum_{i=1}^m \|x_i\|_2^2 = \sum_{i=1}^m \|\hat{x}_i\|_2^2 + \sum_{i=1}^m \|e_i\|_2^2.$$

یعنی «انرژی کل داده» بین «انرژی نگه‌داشته‌شده در زیرفضای انتخابی» و «انرژی باقیمانده/از دست‌رفته» تقسیم می‌شود.

بنابراین در PCA، زیرفضای بهینه طوری انتخاب می‌شود که:

- بیشترین سهم از واریانس (انرژی) را نگه دارد؛

- و معادل آن، کمترین انرژی را در مولفه‌های حذف‌شده باقی بگذارد (کمترین خطای بازسازی).

پس اطلاعات از دست‌رفته دقیقاً برابر با انرژی/واریانس مولفه‌های عمود بر زیرفضای انتخاب‌شده است؛ در حالت کلی k

مولفه، این مقدار برابر مجموع مقادیر ویژه حذف‌شده است:

$$\text{واریانس از دست‌رفته} = \sum_{j=k+1}^n \lambda_j(\Sigma), \quad \text{واریانس حفظ‌شده} = \sum_{j=1}^k \lambda_j(\Sigma),$$

که در آن $\lambda_1 \geq \dots \geq \lambda_n \geq 0$ مقادیر ویژه کوواریانس هستند.

(الف) هم‌راستایی تقریبی PC1 با کدام ویژگی؟

در PCA (وقتی از ماتریس کوواریانس استفاده می‌شود)، جهت PC1 جهتی است که واریانس تصویر داده‌ها روی آن بیشینه شود؛ یعنی بیشترین سهم از انرژی/پراکندگی داده را پوشش دهد. وقتی هیچ استانداردسازی انجام نشده باشد، مقیاس عددی ویژگی‌ها تعیین می‌کند کدام ویژگی بیشترین واریانس را وارد ماتریس کوواریانس می‌کند. در داده حاضر:

- شناسه کاربر یک عدد ترتیبی با مقیاس حدود 10^6 است (واریانس بزرگ، اما از نظر معنایی بی‌ربط).
 - درآمد سالیانه حتی از شناسه هم در مقیاس بسیار بزرگ‌تری است (تا مرتبه 10^{10}).
 - سن، زمان حضور و نرخ تبدیل در مقیاس‌های بسیار کوچک‌تر هستند (ده‌ها، صدها، یا صدم‌ها).
- بنابراین، بدون محاسبه دقیق، انتظار می‌رود PC1 تقریباً با یکی از ویژگی‌های دارای بزرگ‌ترین واریانس عددی هم‌راستا شود؛ در این مسئله معمولاً درآمد سالیانه (و در بسیاری از پیاده‌سازی‌های خام حتی شناسه کاربر اگر پراکندگی آن زیاد باشد) می‌تواند غالب شود. نکته کلیدی این است که PC1 تحت سلطه مقیاس قرار می‌گیرد، نه اهمیت معنایی.
- آیا این مؤلفه برای دسته‌بندی مشتریان ارزشمند است؟ اگر PC1 عمدتاً توسط شناسه کاربر شکل گرفته باشد، از دید تحلیل رفتار مشتری تقریباً بی‌ارزش است؛ چون شناسه یک برجسب ترتیبی است و ساختار هندسی معنی‌دار از رفتار یا ترجیح ایجاد نمی‌کند (فقط عددی بزرگ است). اگر هم PC1 عمدتاً درآمد را پوشش دهد، ممکن است برای تفکیک اقتصادی تا حدی مفید باشد، اما هنوز مشکل اصلی پابرجاست: سایر ویژگی‌های رفتاری (نرخ تبدیل، زمان حضور، سن) به علت مقیاس کوچک‌تر، در مؤلفه‌های ابتدایی کم‌رنگ می‌شوند و فضای PCA ممکن است برای هدف توصیه‌گر، «نماینده رفتار» نباشد [؟].

(ب) سرنوشت نرخ تبدیل در PCA خام

نرخ تبدیل در بازه 0.01 تا 0.05 تغییر می‌کند؛ یعنی تغییرات آن در مقیاس «صدم» است. در مقابل، درآمد یا شناسه در مقیاس‌های میلیون تا ده‌میلیارد نوسان دارند. از آن‌جا که PCA بدون نظارت است و فقط واریانس را بیشینه می‌کند، ویژگی‌هایی با واریانس کوچک معمولاً:

- یا در مؤلفه‌های با رتبه بالاتر (مثلاً PC4, PC5, ...) ظاهر می‌شوند،
- یا اگر با ویژگی‌های بزرگ مقیاس هم‌بستگی قوی نداشته باشند، سهم کمی در PC3-PC1 خواهند داشت.

پس حتی اگر نرخ تبدیل از نظر کسب و کار «مهم‌ترین» ویژگی برای وفاداری باشد، در PCA خام (بدون نرمال‌سازی/استانداردسازی) احتمال زیادی وجود دارد که اثر آن در سه مؤلفه اول دیده نشود؛ زیرا معیار انتخاب مؤلفه‌ها «اطلاعات مفید برای وفاداری» نیست، بلکه «بیشترین واریانس عددی» است

نتیجه عملی برای آن که نرخ تبدیل واقعاً در مؤلفه‌های اولیه نقش بگیرد، باید از پیش‌پردازش‌های متداول مانند استانداردسازی (مثلاً z-score) یا استفاده از ماتریس هم‌بستگی به جای کوواریانس استفاده شود تا هر ویژگی سهمی هم‌تراز از مقیاس داشته باشد.

(ج) چرا تغییر واحد زمان (ثانیه به میکروثانیه) ساختار PCها را عوض می‌کند؟

فرض کنید داده‌ها مرکزسازی شده‌اند و ستون پنجم (زمان حضور) را در ماتریس X با ضریب

$$\alpha = 10^6$$

مقیاس کنیم (چون $1\text{s} = 10^6 \mu\text{s}$). یعنی ستون پنجم جدید:

$$x'_{(5)} = \alpha x_{(5)}.$$

اگر D یک ماتریس قطری باشد که همه درایه‌های قطری آن ۱ هستند به جز درایه پنجم که α است، آنگاه:

$$X' = XD.$$

اکنون کوواریانس نمونه‌ای (طبق صورت سؤال) برابر است با:

$$S = \frac{1}{n-1} X^T X, \quad S' = \frac{1}{n-1} X'^T X' = \frac{1}{n-1} D^T X^T X D = D^T S D.$$

چون D قطری و $D^T = D$ است:

$$S' = D S D.$$

بنابراین:

- درایه قطری مربوط به ویژگی پنجم (واریانس زمان) با ضریب α^2 بزرگ می‌شود:

$$\text{Var}(x'_{(5)}) = \alpha^2 \text{Var}(x_{(5)}).$$

- کوواریانس‌های بین زمان و سایر ویژگی‌ها با ضریب α مقیاس می‌شوند:

$$\text{Cov}(x'_{(5)}, x'_{(j)}) = \alpha \text{Cov}(x_{(5)}, x_{(j)}), \quad j \neq 5.$$

از آن‌جا که مقادیر ویژه و بردارهای ویژه S با این تغییر مقیاس عوض می‌شوند، جهت‌های PC نیز تغییر می‌کنند. اگر α بسیار بزرگ باشد (مثل 10^6)، ستون پنجم می‌تواند به قدری غالب شود که:

- یکی از بزرگ‌ترین مقادیر ویژه تقریباً به واریانس ستون پنجم نسبت داده شود،

- و بردار ویژه متناظر، تقریباً در راستای محور زمان قرار گیرد،

در نتیجه «یک مؤلفه اصلی که تقریباً فقط زمان را می‌بیند» ظاهر می‌شود. این دقیقاً همان حساسیت PCA به واحد و مقیاس در نسخه مبتنی بر کوواریانس است.

تغییر مقیاس یک ویژگی معمولاً فقط «یک مؤلفه» را تغییر نمی‌دهد؛ کل طیف مقادیر/بردارهای ویژه می‌تواند جابه‌جا شود. اما وقتی یک ستون به شدت غالب شود، معمولاً یک جهت غالب (اغلب PC۱ یا یکی از PCهای ابتدایی) عملاً به همان ویژگی قفل می‌شود و سایر مؤلفه‌ها مجبور می‌شوند در زیرفضای عمود بر آن تنظیم شوند.